

학술대회 구두발표 · 1차 실험 보고

TimesFM 3의 다변량 예측, 실제 데이터에서 쓸모가 있는가?

합성 검증에서 METR-LA 16센서·40-origin 모델 비교까지

Hosung Park · 2026-09-02 · 실험 코드와 결과 JSON: [~/Codes/timesfm3-test](#)

먼저 결론 세 줄

1. 다변량 모드는 유효하다. 관련 있는 시계열을 함께 넣으면 오차가 **작지만 반복해서** 줄었다. 교통 데이터 40회 반복에서 평균 1.4~1.7% 개선, 통계 구간이 0을 배제.
2. 같은 조건의 경쟁 모델 Chronos-2보다 오차가 5.2% 낮았다. 40회 중 28회 승리.
3. 그러나 "항상 도움이 된다"도, "도메인 특화 모델보다 낫다"도 아니다. 미래를 설명하지 못하는 입력을 더 넣으면 중립이거나 악화됐고, 도메인 특화 학습 모델과의 비교는 아직 판정 보류.

용어

시계열

시간 순서로 기록된 숫자의 나열. 일별 판매량, 5분마다 전 도로 속도 등.

다변량 예측

여러 시계열을 한꺼번에 넣고 서로 참고하게 하는 예측. 반대말은 단변량(한 줄씩 따로).

오차 개선 %

기준 방법 대비 평균 오차가 얼마나 줄었는지. 음수·'낮다'가 좋은 쪽.

1. 배경

배경: 시계열 예측과 '파운데이션 모델'

전통적 방식은 데이터마다 모델을 새로 학습함. 매장 판매량이면 판매량 모델, 도로 속도면 속도 모델.

2023년 이후 등장한 시계열 파운데이션 모델은 수조 개의 시간점으로 미리 학습해 두고, 새 데이터는 학습 없이 바로 예측함. 마치 언어 모델이 처음 보는 문장을 이어 쓰듯이.

Google의 TimesFM 3(2026년 8월 말 공개)는 그 최신판이고, 이전 버전과 달리 여러 시계열과 보조 정보를 함께 받음.

제작사가 밝힌 사양 (독립 확인 아님)

- 파라미터 3억 3천만 개
- 1조 개 이상의 시간점으로 사전학습
- 여러 타깃 + 과거 전용/미래까지 아는 공변량
- p10~p90 아홉 개 분위수 예측

용어

파운데이션 모델

한 번 크게 학습해 두고 여러 문제에 그대로 쓰는 범용 모델.

zero-shot(제로샷)

새 데이터로 추가 학습(fine-tuning)을 전혀 하지 않고 예측하는 것.

파라미터

모델 안의 조절 가능한 숫자. 많을수록 표현력이 크지만 무겁다.

분위수(p10~p90)

'실제값이 이 값보다 낮을 확률이 10%'인 값이 p10. p10~p90 사이가 80% 예측 구간.

1. 배경

TimesFM 3의 특징은 다변량 모델이라는 것

단변량

시계열 한 줄만 보고 그
줄의 미래를 예측

예: 상품 A 판매량만 보고
A의 다음 4주

다변량(공동 예측)

여러 타깃을 한꺼번에
넣어 서로 참고하게 함

예: 상품 A·B·C 판매량을
함께 넣고 셋 다 예측

과거 전용 공변량

과거 값만 있는 보조 정
보

예: 옆 도로 센서의 지난 7
일 속도

미래까지 아는 공변량

미래 값도 이미 아는 보
조 정보

예: 다음 주 행사 일정, 요
일, 예정 가격

용어

타깃

예측하고 싶은 시계열 그 자체.

공변량(covariate)

예측을 돕기 위해 곁들이는 보조 시계열. 예
측 대상은 아님.

attention

입력의 어느 부분을 얼마나 참고할지 모델
이 스스로 가중치를 매기는 장치.

제작사 발표: 시간 방향 attention과 변수 방향 attention을 번갈아 적용해 여러 입력을 한 번에 처리한다고 설명. 우리는 이 기
능이 실제로 이득을 내는지를 봄.

2. 연구 질문

왜 직접 검증했나: 세 가지 질문

RQ1 관련 시계열을 함께 넣으면 단변량보다 **실제로, 반복해서** 좋아지는가? 아니면 입력이 늘어난 우연인가?

RQ2 그 이득은 입력 사이의 **관계**(옆 도로, 같은 상품)에 달려 있는가? 관계 없는 시계열을 넣으면 중립인가, 해로운가?

RQ3 같은 조건의 **경쟁 zero-shot 모델**(Chronos-2)과 **교통 전용 학습 모델**(DCRNN, STAEformer)에 비해 어디쯤인가?

제작사 벤치는 100개 과제의 평균 순위로만 보고됨. "어떤 데이터에서, 어떤 관계가 있을 때, 얼마나 반복해서" 도움이 되는지는 알 수 없음.

용어

Chronos-2

Amazon이 공개한 경쟁 시계열 파운데이션 모델. 역시 다변량·공변량을 지원.

DCRNN / STAEformer

도로 교통 예측 전용으로 설계돼 해당 데이터로 직접 학습하는 딥러닝 모델들.

벤치마크

여러 모델을 같은 문제 세트로 채점하는 공개 시험지.

일곱 단계: 설계 → 실패 → 재설계 → 엄격화

S0	합성 데이터 인터페이스 확인	정답을 아는 가짜 데이터로 공변량 경로가 작동하는지
S1	실제 데이터 첫 시도	M5 판매량은 성공, Beijing 미세먼지는 실패
S2	재설계 결정	실패를 데이터 문제와 모델 한계로 분리, 대조군 설계
S3	반복 평가	M5 재구성, METR-LA 교통 10회, 외부 벤치 3개
S4	엄격화	정보 누수 차단, 40회 반복, 통계 구간
S5	모델 비교	Chronos-2, DCRNN, STAEformer를 같은 조건에서
S6	결론과 경계	무엇을 말할 수 있고 무엇이 아직인지

용어

사전 고정(pre-registration)

결과를 보기 전에 데이터·평가 규칙을 정해 두는 것. 좋은 결과만 골라 보고하는 편향을 막는다.

사후 해석

결과를 본 뒤에 붙인 해석. 이 발표에서는 매 번 구분해 표시함.

4. 평가 방법

어떻게 채점했나

오차 지표: MAE (Mean Absolute Error, 평균 절대 오차)

예측이 실제와 얼마나 떨어졌는지를 재는 가장 기본적인 지표. 예측 구간의 매 시점마다 $|\text{예측} - \text{실제}|$ 를 구해 평균 냄. 예: 실제 속도 60 mph를 57로 예측하면 그 시점 오차는 3. 부호를 없애므로 위아래 빗나감이 상쇄되지 않고, 단위가 데이터와 같아(mph, 개, $\mu\text{g}/\text{m}^3$) 바로 읽힘. 낮을수록 좋음.

기준선: seasonal naive

예측 분야에서 가장 널리 쓰는 기본 비교 대상. "지난 주기와 똑같이 반복된다"고 가정해, 일별 데이터면 지난주 같은 요일 값을, 시간별 데이터면 어제 같은 시각 값을 그대로 씬. 계산이 필요 없는 이 방법을 이기지 못하면 복잡한 모델을 쓸 이유가 없음.

평가 방식: holdout과 rolling origin

시계열의 마지막 구간을 정답으로 숨겨 두고 그 앞까지만 모델에 보여준 뒤 맞히게 하는 것이 **holdout** 평가. 한 번만 하면 그 구간의 특수한 사정(휴일, 사고)에 결과가 좌우됨. 그래서 예측 시작 시점(origin)을 여러 번 옮겨 가며 같은 평가를 반복하는 **rolling origin**을 씬. 반복 횟수가 많을수록 우연이 걸러짐.

비교 방법: 승률과 paired 차이

같은 시작 시점에서 두 방법의 MAE 차이를 구해 (paired) 평균 내고, 몇 번 이겼는지(승률)를 셈. 차이의 평균에는 "다시 해도 같은 방향일까"를 나타내는 **불확실성 구간**을 붙임.

용어

holdout

정답을 숨겨 둔 평가 구간. 모델은 그 앞까지만 봄.

origin

예측을 시작하는 시점. 그 앞이 context(입력), 뒤가 horizon(예측 구간).

context / horizon


모델이 보는 과거 길이 / 맞혀야 하는 미래 길이.

coverage

p10~p90 예측 구간 안에 실제값이 들어온 비율. 80%에 가까우면 불확실성 표현이 정직한 것.

5. 결과 · S0

S0. 정답을 아는 가짜 데이터로 '배선'부터 확인



가상의 두 상품 수요를 **직접 만든 식**으로 생성. 프로모션이 있는 날 수요가 정확히 **32.8 / 21.0**만큼 오르도록 설계.

모델에 미래 프로모션 일정(11일)을 알려주자, 모델이 부여한 상승폭은 **32.55 / 21.74**. 일정을 지운 반사실 실행에서는 봉우리가 사라짐.

이것은 성능 증거가 아님. 공변량 입력 경로가 작동한다는 확인일 뿐. 오차가 62% 줄어든 것도 우리가 그렇게 만들었기 때문임.

노란 띠 = 예정 프로모션. 주황(단변량)·회색(seasonal naive)은 주간 봉우리만 따라가고, 파랑(다변량+공변량)만 프로모션 봉우리를 재현.

용어

합성 데이터

연구자가 수식으로 생성한 데이터. 정답 효과를 알 수 있어 도구 점검에 씬.

반사실(counterfactual)

'만약 프로모션이 없었다면'처럼 입력 하나만 바꿔 다시 예측해 그 입력의 기여를 재는 방법.

lift

프로모션 하루가 수요를 끌어올린 양.

S1. 실제 데이터 첫 시도: 하나는 성공, 하나는 실패

M5 Walmart 판매량 (16개 상품, 512일 → 28일)

방법	MAE
seasonal naive	8.41
TimesFM 3 단변량	6.67
다변량	6.59
다변량+공변량	6.55

naive보다 **22.1%** 개선. 다변량·공변량의 추가 이득은 1.8%로 작지만 같은 방향.

Beijing 미세먼지 (4개 관측소, 14일 → 24시간)

방법	MAE
seasonal naive	22.54
TimesFM 3 단변량	23.11
다변량	28.35
다변량+공변량	29.12

입력을 더 넣을수록 **나빠짐**. 다변량+공변량은 seasonal naive보다 29.2% 나쁨. 80% 예측 구간의 실제 적중률은 43~54%.

여기서 seasonal naive는 "어제 같은 시각 값을 반복"한 것. 실제 농도가 9 근처로 급락해 모든 방법이 위로 빗나갔고, 단변량 (23.11)과 거의 같은 수준에서 반복 패턴이 우연히 조금 덜 높았을 뿐임. naive가 좋은 예측이라는 뜻이 아니라 모두가 틀린 사례.

용어

M5

Walmart 판매 데이터 공개 대회 자료. 상품 별 일별 판매량과 가격·행사 정보 포함.

SNAP


미국 식품 지원 프로그램. 지급일에 판매가 뛰어 공변량으로 사용.

PM2.5

지름 2.5μm 이하 초미세먼지 농도.

5. 결과 · S2

실패에서 배운 것: 공변량은 '개수'가 아니라 '미래를 설명하는가'



예측 구간의 실제 평균 농도는 **9.4**. 직전 24시간 평균은 약 31, 2주 평균은 86 안팎. **갑작스러운 청정 전환**이었음.

모델이 받은 보조 정보는 시간대·요일 뿐. 바람이 바뀔 것이라는 정보는 어디에도 없었으니, 어떤 모델도 맞힐 수 없는 **외부 충격**임.

실제 미래 기상값을 넣으면 맞겠지만 그건 **정보 누수**. 이 사례는 다변량 예측의 실패가 아니라 **레짐 전환·과신 스트레스 테스트**로 재분류함(사후 해석).

재설계 결정(S2): 관계가 실제 선행정보가 되는 데이터에서, 관련 입력 vs 무관 입력 **대조군**을 같은 시점에 비교.

용어

레짐 전환

데이터의 수준·패턴이 갑자기 다른 상태로 바뀌는 것.

정보 누수(leakage)

예측 시점에 알 수 없었던 미래 정보가 입력에 섞여 성능이 부풀려지는 오류.

과신

예측 구간이 실제보다 좁아 틀릴 때 크게 틀리는 상태.

주 실험 데이터: METR-LA 로스앤젤레스 고속도로 센서

- 2012년 3~6월, **207개 센서**가 5분마다 통행 속도 (mph) 기록
- 센서 간 **도로 방향과 거리**가 공개돼 있음
- 정체는 상류에서 하류로 **전파**되므로 옆 센서가 실제 선행정보가 될 수 있음
- DCRNN·STAEformer 등 교통 전용 모델의 표준 시험 데이터

왜 16개 센서만?

첫 질문은 "다변량 기능이 작동하는가"였음. 16개면 제한된 계산 자원으로 모든 조건을 같은 시점에서 비교할 수 있음. 207개 전체는 별도 2단계로 분리.

타깃 16개

도로망 거리로 묶은 센서 클러스터

인접 센서 4개

타깃별 도로망 최근접, 평균 1.66 km → **관련 입력**

원거리 센서 4개

타깃별 가장 먼 센서, 평균 26.8 km → **대조군**

같은 크기의 입력을 넣고 결과가 갈리면, 이득이 '관계'에서 왔다고 볼 수 있음.

용어

대조군(negative control)

효과가 없어야 정상인 조건. 관련 없는 먼 센서를 넣어 '입력이 늘어난 효과'와 '관계의 효과'를 구분.

도로 그래프

센서를 점, 도로 연결을 선으로 표현한 구조. 거리·방향 정보 포함.

mph

시간당 마일. 오차 1 mph $\approx$ 시속 1.6 km 차이.

S3. 탐색 결과 (10회 반복): 관련 입력과 무관 입력이 같았다

입력 방식	MAE (MPH)	단변량 대비	승률
seasonal naive	10.18	+200%	0/10
TimesFM 3 단변량	3.39	—	—
16개 타깃 공동 예측	3.17	-6.36%	8/10
인접 센서 입력	3.22	-4.97%	9/10
원거리 센서 대조군	3.42	+0.84%	6/10

관련 입력은 좋아지고 무관 입력은 나빠졌음. RQ2에 긍정적인 첫 신호.

하지만 10회로는 부족했음. 10개 origin이 2주 안에 몰려 서로 독립이 아니고, 극단 하루가 평균을 흔들 수 있으며, 불확실성 구간을 계산하지 않았음. 센서 선택 구간이 평가 구간과 너무 가까웠음.

용어

승률 8/10

10번의 예측 시작점 중 8번에서 단변량보다 오차가 낮았다는 뜻.

negative transfer

관계 없는 입력이 오히려 예측을 방해하는 현상.

S4. 엄격화: 10회 결과의 약점 세 가지에 조치 하나씩

10회 결과(6% 개선)는 고무적이었지만 그대로 발표하기에는 세 가지 약점이 있었음. 각 약점에 대응하는 조치를 하나씩 정해 다시 실험함.

약점 ① 센서를 고를 때 평가 구간의 정보를 볼 수 있었음

어떤 센서를 타깃으로 삼을지 결측률로 고르는데, 그 계산 구간이 평가에 쓰는 입력 구간과 겹칠 수 있었음. 결과를 보고 고른 것과 같은 효과(정보 누수).

조치: 센서 선택은 시계열 앞 절반(34,272 중 17,136 시점)만으로, 평가 입력은 18,111 시점 이후만. 975 시점 간격.

약점 ② 시작점이 10개뿐이고 2주 안에 몰려 있었음

표본이 적고 서로 비슷한 날들이라, 극단적인 하루가 평균을 흔들 수 있음.

조치: 서로 겹치지 않는 시작점 40개(2012-05-09 ~ 06-25, 하루 이상 간격). 7일 입력 → 1시간 예측은 유지.

약점 ③ "우연인가"를 판단할 근거가 없었음

평균 차이만 있고 그 흔들림을 재지 않았음. 이웃한 날끼리는 상관관계가 있어 보통의 통계 검정을 그대로 쓰기도 어려움.

조치: 40개 차이값을 7개씩 묶어 무작위 재추출을 10,000번 반복해 평균 차이의 95% 범위를 구함(블록 부트스트랩). 범위가 0을 벗어나면 방향이 안정적이라고 봄.

용어

부트스트랩

가진 표본을 무작위로 다시 뽑아 통계량의 흔들림을 재는 방법.


블록 부트스트랩

시간 순서가 있는 데이터에서 연속 구간(블록)째로 뽑아 이웃 상관을 보존하는 변형.

95% 구간이 0을 배제

다시 뽑아도 평균 차이가 거의 항상 같은 부호였다는 뜻. '효과가 우연은 아닐 가능성이 높다.'

S4. 40회 결과: 이득은 1~2%로 줄었지만 '반복'됐다



입력 방식	MAE	단변량 대비	승
단변량	2.611	—	—
공동 예측	2.576	-1.38%	30/40
인접 센서	2.566	-1.73%	29/40
원거리 대조군	2.607	-0.17%	23/40
인접+캘린더	2.566	-1.74%	32/40

95% 구간: 공동·인접·인접+캘린더는 구간이 **0 아래** (예: 공동 [-0.059, -0.011]). 원거리 대조군은 0을 포함([-0.031, 0.016]).

10회의 5~6%가 40회에서 **1~2%**로. 실패가 아니라 **주장이 정확하게 보정된 것**. 관련 입력은 반복 개선, 대조군은 중립.

인접 - 원거리 직접 비교 구간은 [-0.087, 0.003]으로 상한이 0을 살짝 넘어, '관계 선택의 우월성'은 시사적·미확정. 그림 아래 패널: TimesFM 모드의 차이는 0 근처에 몰려 있고, 비교용 선형 회귀 기준선들은 대부분 위쪽.

용어

MAE 2.611

40회 평균. 실제 속도와 예측이 평균 2.6 mph 차이.

[-0.059, -0.011]

다시 뽑아 구한 평균 차이의 95% 범위. 둘 다 음수 = 개선 방향이 안정적.

S5. 모델 비교 설계: 두 트랙을 섞지 않는다

트랙 A Zero-shot 파운데이션 모델

- TimesFM 3 (Google) vs Chronos-2 (Amazon)
- 같은 16센서, 같은 40개 시작점, 같은 7일 입력 (2,016 시점)
- 이 데이터로 학습 **전혀 없음**

트랙 B 교통 전용 학습 모델

- DCRNN (도로 그래프 신경망) vs STAEformer (트랜스포머)
- 시계열 앞 절반(13,685개 창)으로 **직접 학습**, 검증 오차로 조기 종료
- 표준 설정: 1시간 입력 → 1시간 출력. 각 1회 (seed 1개) 학습

두 트랙은 학습 예산과 입력 정보량이 다르므로 **한 줄의 순위표로 읽지 않음**. 전용 모델이 낮으면 '도메인 학습의 상한', zero-shot이 근접하면 '학습 없이 얻은 효율'로 해석함. 평가 40개 시작점은 어떤 모델 선택에도 쓰지 않았음.

용어

supervised(지도) 학습

정답이 있는 과거 데이터로 모델의 파라미터를 직접 맞추는 것.

seed


학습의 무작위 초기값. 하나만 돌리면 운에 따른 편차를 썰 수 없다.

조기 종료

검증 오차가 더 안 줄면 학습을 멈추는 규칙. 과적합 방지.

S5. 두 도메인 특화 모델은 어떻게 학습했나

항목	DCRNN	STAEFORMER
구조	도로 인접행렬 위 diffusion convolution + GRU 인코더·디코더(은 닉 64, 확산 2단계)	Transformer 3층·4 head, 시간대·요일·적응형 임베딩 (24/24/80), 그래프 입력 없 음
파라미터	372,353	1,075,620
입력 → 출력	12 시점(1시간) → 12 시점(1시간), 속도 정규화 후 학습	
학습 데이터	시계열 앞 절반만 사용. 학습 창 13,685개, 검증 창 3,417 개(시간순 분할). 평가 40개 시작점은 사용 안 함	
손실·최적화	MAE, Adam lr 0.01, 20·30·40·50 epoch에 ×0.1, grad clip 5	MAE, Adam lr 0.001, weight decay 3e-4, 20·30 epoch에 ×0.1
종료 규칙	최대 50 epoch, 검증 MAE 8회 연속 비개선이면 중단, 검 증 최선 epoch의 가중치 채택	
실행 결과	41 epoch, 최선 33(검증 2.395), CPU 25.0분	31 epoch, 최선 23(검증 2.407), MPS 15.0분
재현성	seed 20260902 1회, Torch-MTS 고정 커밋, 체크포인트 를 새 인스턴스에 로드해 40회 재평가로 저장값과 일치 확 인	



epoch별 검증 MAE. 실선 DCRNN, 점선 STAEformer, 점은 채택한 최선 epoch. 둘 다 20 epoch 근처의 학습률 감쇠 뒤 수렴했고 검증 오차는 2.40 안팎으로 비슷함. 40회 평가 MAE(2.74, 2.80)가 검증 값보다 높은 것은 평가 구간이 학습 구간보다 뒤이고 결측 없는 날만 골랐기 때문.

용어

epoch

학습 데이터 전체를 한 번 훑는 단위.

검증 세트

학습에 쓰지 않고 '언제 멈출지'와 '어느 epoch를 쓸지'를 정하는 데만 쓰는 데이터.


학습률 감쇠

학습이 진행되면 보폭(학습률)을 줄여 미세 조정하는 규칙.

seed

학습의 무작위 초기값. 1회만 돌렸으므로 운에 따른 편차는 재지 않았음.

S5. 결과: Chronos-2보다 낮고, DCRNN과는 판정 보류



모델	MAE	VS TIMESFM MV	판정
TimesFM 3 다변량	2.576	-	-
TimesFM 3 단변량	2.611	+1.4%	0 배제
Chronos-2 다변량	2.718	+5.5%	0 배제
DCRNN (학습)	2.741	+6.4%	0 포함
STAEformer (학습)	2.802	+8.8%	0 배제

95% 구간(해당 모델 - TimesFM 다변량): Chronos-2 [-0.193, -0.095]는 TimesFM 기준, DCRNN [-0.006, 0.371], STAEformer [0.038, 0.446].

TimesFM 3 다변량은 Chronos-2 다변량보다 5.24% 낮고 28/40 승. Chronos-2 자체의 다변량 이득은 구간 이 0을 포함.

DCRNN과는 우열 미확정. 평균 차이 +0.17의 97%가 4개 시작점(특히 36번, +4.03)에서 나왔고 중앙값은 +0.04, DCRNN이 16/40 승. 어려운 며칠을 빼면 차이가 사라지므로 승패를 선언하지 않음.

표의 %는 해당 모델 기준(+5.5%)이고 논문은 TimesFM 기준(-5.24%)으로 적음. 같은 차이를 어느 쪽으로 나누느냐의 차이.

보조 실험: M5 판매량에서는 '관계 특이적' 이득이 없었다

입력 방식 (같은 8개 상품 × 캘리포니아 3개 매장 = 24 타깃, 5회 반복)	MAE	단변량 대비
TimesFM 3 단변량	9.85	—
24개 타깃 공동 예측	9.39	-4.73%
같은 상품·다른 매장을 보조 입력으로 (관련 입력)	9.83	-0.21%
다른 상품·다른 매장을 보조 입력으로 (대조군)	9.42	-4.34%

공동 예측의 이득은 있었지만, '같은 상품'이라는 관계는 대조군보다 낮지 않았음. 즉 판매 데이터에서는 입력을 묶는 일반적 효과이지, 매장 간 동일 상품 정보가 특별히 유효하다는 증거가 아님.

5회 반복으로는 작은 차이를 확정할 수 없음. 교통 데이터와 대비되는 결과로, "관계가 실제 선행정보인가"가 관건임을 보여줌.

용어

SKU

재고 관리 단위. 여기서는 '상품 하나'.

관계 특이적 이득

아무 시계열이 아니라 '바로 그 관계'가 있는 시계열이어야 생기는 이득.

외부 검증: 구글 공개 수치를 재현할 수 있었나

FEV-BENCH 과제	로컬 SQL	구글 공개 SQL	차이	데이터 지문 일치
ETT_1W (변압기 유온·부하 7변수)	2.434	2.401	+1.40%	아니오
UCI Air Quality 1D (대기질 4타겟)	1.030	1.091	-5.54%	아니오
GVAR (6타겟+과거 공변량)	0.568	0.567	+0.19%	아니오

세 과제의 절대 차이 평균 **2.38%**. 같은 환경에서 다시 돌리면 소수점까지 동일(결정적).

현재 내려받은 데이터의 지문이 구글 기록과 모두 달라, 이것은 **근접 재현**이지 비트 단위 재현이 아님. 100개 과제 전체를 재현했다고도 말하지 않음.

용어

FEV-Bench

AutoGluon이 만든 공개 예측 벤치마크. 구글이 TimesFM 3 성적표를 여기에 공개.

SQL

Scaled Quantile Loss. 확률 예측의 정확도 지표. 낮을수록 좋음.

데이터 지문(fingerprint)

데이터 파일 내용의 요약값. 다르면 같은 이름이라도 내용이 다르다는 뜻.

언제 돕고, 언제 해치는가

도움이 된 조건

- 입력에 실제 선행정보가 있을 때 — 옆 도로 센서(정체 전파)
- 미래에 이미 아는 변화를 공변량으로 줄 때 — 행사·가격·SNAP
- 타깃끼리 공통 변동을 공유할 때 — 공동 예측(판매·교통 모두)

중립이거나 해친 조건

- 미래 변화의 원인이 입력에 없을 때 — Beijing 청정 전환
- 관계 약한 시계열을 섞을 때 — 먼 센서: 10회에서는 악화, 40회에서는 중립
- 반복 주기만 설명하는 공변량을 짧은 예측에 더할 때 — 1시간 예측에 요일 정보

40회에서 다변량 이득은 MAE 약 0.04 mph, 상대 1~2%. 실무적으로 작지만 **추가 학습 없이 입력 구성만으로 반복 획득되는 이득**임. 같은 조건에서 Chronos-2는 이 이득을 보이지 않았음. 다만 그 차이가 모델 구조 때문인지 사전학습 데이터 때문인지는 이 실험으로 분리할 수 없음.

용어

선행정보

미래 값이 움직이기 전에 먼저 움직이는 신호. 상류 정체는 하류 정체의 선행정보.

입력 선택

어떤 시계열을 함께 넣을지 고르는 일. 모델이 알아서 걸러 주지 않는다는 것이 이번 교훈.

보험 업무에서 다변량 예측이 필요한 사례 (가설)

사례	함께 넣을 시계열	단변량보다 나을 것으로 기대하는 이유	경로
채널별 고객센터 인입량	전화·챗·앱·지점별 일별 건수	납입일·갱신·사고 급증이 모든 채널을 함께 움직이고, 한 채널의 혼잡이 다른 채널로 넘어감	A B
담보별 청구 접수 건수	대물·대인·자차, 실 손 통원·입원	한 사고가 여러 담보 청구로 동시에 이어지고 기상·연휴가 담보 전체에 걸림	A
청구 처리 파이 프라인	접수 → 심사 대기 → 지급 완료	접수량이 며칠 뒤 지급량을 결정하는 상류→하류 구조. METR-LA 인접 센서와 같은 형태로, 이 연구에서 가장 일관된 이득이 난 조건	B
지역·정비공장 별 수리비	지역별 청구액 + 부품 가·공임 지수	부품가·공임 변동이 모든 지역에 공통으로 걸림	A B
수납·이체 실패 ·실패 건수	수납, 이체 실패, 실패 ·해지	이체 실패가 실패의 선행 지표, 급여일·명절이 셋을 함께 움직임	A B C
담보별 월간 지급 현금흐름	담보별 지급액 + 접수 건수	접수가 지급의 선행 지표. 준비금 추정의 보조 기준선	A B
신상품·신규 지 역 접수량	신규 시계열 + 관련 기존 시계열	짧은 이력 대신 관련 시계열의 계절·행사 반응을 빌림	A

경로는 이 연구에서 확인된 세 가지 이득 경로. **A** 공통 변동 공유 → 공동 예측(M5 -4.7%, METR-LA -1.4%) · **B** 선행 정보 → 과거 전용 공변량(인접 센서 -1.7%, 원거리 대조군은 중립) · **C** 미래 확정 정보 → known-future 공변량(M5 -1.8%). 기대 효과는 1~5%를 넘지 않는다고 보는 것이 안전함.

용어

담보

보험이 보상하는 항목 단위. 대물(남의 물건), 대인(사람), 자차(내 차) 등.

실패

보험료 미납으로 계약 효력이 정지된 상태. 해지의 전 단계.

선행 지표

다른 값이 움직이기 전에 먼저 움직이는 시계열.

보험 응용: 부적합 영역과 사내 검증 절차 (가설)

부적합하거나 주의

- **태풍·폭우·한파 청구 급증** — Beijing과 같은 외생 전환. 예보만 공변량으로, 실제 미래 기상값은 누수
- **제도·요율 변경 직후** — 변경 시점을 알려주지 않으면 근거 없음
- **손해율·발생손해액** — 희소 사건·두꺼운 꼬리, 실험 범위 밖
- **계약별 해지·사고 확률** — 분류 문제, 대상 아님. 집계 건수만 해당
- **관계 약한 시계열 묶음** — 원거리 대조군처럼 중립, 준비 비용만 듬

사내 검증 절차

- **입력 선택은 사람이** — 모델이 무관한 입력을 걸러 주지 않음
- **seasonal naive 대비**, 40개 이상 비중첩 rolling origin
- **사례별 대조군** — 무관한 채널·담보·지역을 같은 크기로 넣어 비교
- **paired block-bootstrap 구간**으로 방향의 안정성 확인
- **시작 사례**: 청구 파이프라인, 채널별 인입량

용어

손해율

받은 보험료 대비 지급한 보험금의 비율.

분류 문제

'해지한다/안 한다'처럼 범주를 맞추는 과제. 시계열의 다음 값을 맞추는 예측과 다름.

대조군

효과가 없어야 정상인 비교 조건. 무관한 시계열을 같은 크기로 넣어 '관계의 효과'를 분리.

검증 전에는 결론이 아니라 검토 항목. 가치는 정확도보다 "학습 없이 즉시 기준선"의 속도에 있음. 현재 라이선스는 비상업·비프로덕션 전용이라 내부 비교 연구 범위임.

7. 한계

한계: 이 결과가 말하지 않는 것

16센서 부분 그래프

전용 모델은 207개 중 16개만으로 학습. 바깥 이웃이 잘려 **그래프 모델에 불리**할 수 있음. 공개된 DCRNN·STAEformer 표준 점수와 직접 비교 금지.

입력 길이 불일치

zero-shot은 7일(2,016 시점), 전용 모델은 표준 1시간(12 시점). 정보량이 다름.

학습 1회

전용 모델을 seed 하나로만 학습. 초기값에 따른 편차 미측정. DCRNN과의 구간이 0에 걸친 상태에서 어느 쪽으로도 움직일 수 있음.

사전학습 중복 미확인

TimesFM 3·Chronos-2가 사전학습 때 METR-LA를 봤는지 독립 확인 불가. 여기서 zero-shot은 '로컬 학습 없음'의 뜻.

작은 시간 창

40개 시작점은 7주 안에 있고, 결측 없는 구간만 선택. 전체 기간의 무작위 표본이 아님. 다중비교 보정 없음.

라이선스

TimesFM 3 가중치는 **비상업·비프로덕션** 전용. 이 결과로 운영 배포를 정당화할 수 없음.

용어

induced subgraph

전체 그래프에서 일부 점만 남기고 그 사이 연결만 유지한 부분 그래프.

다중비교

여러 비교를 동시에 하면 우연히 하나쯤은 유의해 보일 수 있는 문제.

8. 결론

결론과 다음 단계의 경계

TimesFM 3의 다변량 모드는 유용하며, 시계열 사이에 실제 신호가 있을 때 작지만 반복 가능한 이득을 낸다. 같은 16센서 METR-LA zero-shot 조건에서 Chronos-2보다 우수했다. 이 결과는 TimesFM 3가 DCRNN·STAEformer보다 일반적으로 우월하다는 것도, 다변량 입력이 항상 도움이 된다는 것도 확립하지 않는다.

연구 질문별 답

- **RQ1** 예, 단 작다(-1.4~-1.7%, 구간 0 배제)
- **RQ2** 부분적으로 예. 교통에서는 관계가 같았고 판매에서는 아니었다
- **RQ3** Chronos-2보다 낮음. DCRNN 미확정. STAEformer보다 이 패널에서 낮음

2단계를 여는 조건 (지금은 열지 않음)

- 207개 센서 전체와 표준 분할, 15·30·60분 지표
- 전용 모델 seed 3개 이상
- zero-shot 모델의 입력 길이 12 vs 2,016 비교
- 학습 비용과 추론 비용의 분리 보고

용어

표준 분할

해당 분야 논문들이 공통으로 쓰는 학습/검증/평가 구간 나누기. 결과를 서로 비교하려면 필요.

재현 정보

환경

- Apple M4 · macOS 26.5.2 · Python 3.13.12
· torch 2.13.0 · MPS
- TimesFM 소스 커밋 7360853 · 가중치
google/timesfm-3.0-pytorch
- Chronos-2: amazon/chronos-2, chronos-
forecasting 2.3.1
- DCRNN·STAEformer: Torch-MTS 커밋 2db4de3
- FEV 0.9.0 · uv.lock으로 의존성 고정

검증

- 원본 데이터 5개 파일 체크섬 일치
- 결과 JSON 11개에서 모든 표를 재계산
- 학습 모델 체크포인트를 새 인스턴스에 로드해 40회 재평가
- Chronos-2 재실행이 저장 결과와 일치
- 테스트 26개 통과, 정적 검사 통과

데이터 출처

M5: Kaggle (Zenodo 보존본) · Beijing: UCI, CC BY 4.0 ·
METR-LA: DCRNN 저장소 공개 파일 · FEV: AutoGluon

용어

체크섬

파일 내용의 지문. 내려받은 파일이 원본과
같은지 확인.

체크포인트

학습 도중 저장한 모델의 파라미터 파일.

용어 한 장 정리

시계열	시간 순서의 숫자 나열
공변량	예측을 돕는 보조 시계열 (과거 전용 / 미래까지 아는)
파운데이션 모델	미리 크게 학습해 둔 범용 모델
seasonal naive	"지난 주기와 같다"고 반복하는 기본 비교 대상
rolling origin	시작점을 옮겨가며 반복 평가
정보 누수	미래 정보가 입력에 섞이는 오류
supervised	해당 데이터로 직접 학습한 모델

단변량 / 다변량	한 줄씩 따로 / 여러 줄을 함께
zero-shot	추가 학습 없이 바로 예측
MAE	예측 오차 절댓값의 평균
holdout / origin	숨겨둔 평가 구간 / 예측 시작 시점
대조군	효과가 없어야 정상인 비교 조건
블록 부트스트랩 구간	연속 구간째 재추출로 구한 평균 차이의 범위
레짐 전환	데이터 패턴이 갑자기 바뀌는 것

감사합니다

질문 환영

논문 v10과 결과 JSON, 체크포인트, 재현 명령은 프로젝트 저장소 docs/와 artifacts/에 있음.