

학술대회 구두발표 · 1차 실험 보고

TimesFM 3의 다변량 예측, 실제 데이터에서 쓸모가 있는가?

합성 검증에서 METR-LA 16센서·40-origin 모델 비교까지

Hosung Park · 2026-09-02 · 실험 코드와 결과 JSON: [~/Codes/timesfm3-test](#)

먼저 결론 세 줄

1. 다변량 모드는 유효하다. 관련 있는 시계열을 함께 넣으면 오차가 **작지만 반복해서** 줄었다. 교통 데이터 40회 반복에서 평균 1.4~1.7% 개선, 통계 구간이 0을 배제.
2. 같은 조건의 경쟁 모델 Chronos-2보다 오차가 5.2% 낮았다. 40회 중 28회 승리.
3. 그러나 "항상 도움이 된다"도, "교통 전용 모델보다 낫다"도 아니다. 미래를 설명하지 못하는 입력을 더 넣으면 중립이거나 악화됐고, 전용 학습 모델과의 비교는 아직 판정 보류.

용어

시계열

시간 순서로 기록된 숫자의 나열. 일별 판매량, 5분마다 전 도로 속도 등.

다변량 예측

여러 시계열을 한꺼번에 넣고 서로 참고하게 하는 예측. 반대말은 단변량(한 줄씩 따로).

오차 개선 %

기준 방법 대비 평균 오차가 얼마나 줄었는지. 음수·'낮다'가 좋은 쪽.

1. 배경

배경: 시계열 예측과 '파운데이션 모델'

전통적 방식은 데이터마다 모델을 새로 학습함. 매장 판매량이면 판매량 모델, 도로 속도면 속도 모델.

2023년 이후 등장한 **시계열 파운데이션 모델**은 수조 개의 시간점으로 미리 학습해 두고, 새 데이터는 **학습 없이 바로** 예측함. 마치 언어 모델이 처음 보는 문장을 이어 쓰듯이.

Google의 **TimesFM 3**(2026년 8월 말 공개)는 그 최신판이고, 이전 버전과 달리 **여러 시계열과 보조 정보를 함께** 받음.

제작사가 밝힌 사양 (독립 확인 아님)

- 파라미터 3억 3천만 개
- 1조 개 이상의 시간점으로 사전학습
- 여러 타깃 + 과거 전용/미래까지 아는 공변량
- p10~p90 아홉 개 분위수 예측

용어

파운데이션 모델

한 번 크게 학습해 두고 여러 문제에 그대로 쓰는 범용 모델.

zero-shot(제로샷)

새 데이터로 추가 학습(fine-tuning)을 전혀 하지 않고 예측하는 것.

파라미터

모델 안의 조절 가능한 숫자. 많을수록 표현력이 크지만 무겁다.

분위수(p10~p90)

'실제값이 이 값보다 낮을 확률이 10%'인 값이 p10. p10~p90 사이가 80% 예측 구간.

1. 배경

TimesFM 3가 새로 내세운 것: 입력을 '함께' 본다

단변량

시계열 한 줄만 보고 그
줄의 미래를 예측

예: 상품 A 판매량만 보고
A의 다음 4주

다변량(공동 예측)

여러 타깃을 한꺼번에
넣어 서로 참고하게 함

예: 상품 A·B·C 판매량을
함께 넣고 셋 다 예측

과거 전용 공변량

과거 값만 있는 보조 정
보

예: 옆 도로 센서의 지난 7
일 속도

미래까지 아는 공변량

미래 값도 이미 아는 보
조 정보

예: 다음 주 행사 일정, 요
일, 예정 가격

용어

타깃

예측하고 싶은 시계열 그 자체.

공변량(covariate)

예측을 돕기 위해 곁들이는 보조 시계열. 예
측 대상은 아님.

attention

입력의 어느 부분을 얼마나 참고할지 모델
이 스스로 가중치를 매기는 장치.

제작사 발표: 시간 방향 attention과 변수 방향 attention을 번갈아 적용해 여러 입력을 한 번에 처리한다고 설명. 우리는 이 기
능이 실제로 이득을 내는지를 봄.

2. 연구 질문

왜 직접 검증했나: 세 가지 질문

RQ1 관련 시계열을 함께 넣으면 단변량보다 **실제로, 반복해서** 좋아지는가? 아니면 입력이 늘어난 우연인가?

RQ2 그 이득은 입력 사이의 **관계**(옆 도로, 같은 상품)에 달려 있는가? 관계 없는 시계열을 넣으면 중립인가, 해로운가?

RQ3 같은 조건의 **경쟁 zero-shot 모델**(Chronos-2)과 **교통 전용 학습 모델**(DCRNN, STAEformer)에 비해 어디쯤인가?

제작사 벤치는 100개 과제의 평균 순위로만 보고됨. "어떤 데이터에서, 어떤 관계가 있을 때, 얼마나 반복해서" 도움이 되는지는 알 수 없음.

용어

Chronos-2

Amazon이 공개한 경쟁 시계열 파운데이션 모델. 역시 다변량·공변량을 지원.

DCRNN / STAEformer

도로 교통 예측 전용으로 설계돼 해당 데이터로 직접 학습하는 딥러닝 모델들.

벤치마크

여러 모델을 같은 문제 세트로 채점하는 공개 시험지.

하루 동안의 일곱 단계: 설계 → 실패 → 재설계 → 엄격화

S0	합성 데이터 인터페이스 확인	정답을 아는 가짜 데이터로 공변량 경로가 작동하는지
S1	실제 데이터 첫 시도	M5 판매량은 성공, Beijing 미세먼지는 실패
S2	재설계 결정	실패를 데이터 문제와 모델 한계로 분리, 대조군 설계
S3	반복 평가	M5 재구성, METR-LA 교통 10회, 외부 벤치 3개
S4	엄격화	정보 누수 차단, 40회 반복, 통계 구간
S5	모델 비교	Chronos-2, DCRNN, STAEformer를 같은 조건에서
S6	결론과 경계	무엇을 말할 수 있고 무엇이 아직인지

용어

사전 고정(pre-registration)

결과를 보기 전에 데이터·평가 규칙을 정해 두는 것. 좋은 결과만 골라 보고하는 편향을 막는다.

사후 해석

결과를 본 뒤에 붙인 해석. 이 발표에서는 매 번 구분해 표시함.

4. 평가 방법

어떻게 채점했나

주지표: MAE (평균 절대 오차)

예측값과 실제값의 차이를 절댓값으로 평균. 단위가 원래 데이터와 같아 직관적임. 교통은 mph, 판매는 개수, 미세먼지는 $\mu\text{g}/\text{m}^3$.

기준선: 계절 naive

"지난주와 똑같은 것"이라고 찍는 가장 단순한 방법. 이것도 못 이기면 모델을 쓸 이유가 없음.

단일 holdout vs rolling origin

맨 끝 한 구간만 숨기고 맞히면 **단일 holdout**: 한 번의 관측. 예측 시작점을 옮겨 가며 여러 번 반복하면 **rolling origin**: 우연을 걸러냄.

승률과 paired 차이

반복마다 "A가 B보다 좋았나"를 세고, 차이의 평균에 **불확실성 구간**을 붙임.

용어

holdout

정답을 숨겨 둔 평가 구간. 모델은 그 앞까지만 봄.

origin

예측을 시작하는 시점. 그 앞이 context(입력), 뒤가 horizon(예측 구간).


context / horizon

모델이 보는 과거 길이 / 맞혀야 하는 미래 길이.

coverage

p10~p90 예측 구간 안에 실제값이 들어온 비율. 80%에 가까우면 불확실성 표현이 정직한 것.

S0. 정답을 아는 가짜 데이터로 '배선'부터 확인



가상의 두 상품 수요를 직접 만든 식으로 생성. 프로모션이 있는 날 수요가 정확히 **32.8 / 21.0**만큼 오르도록 설계.

모델에 미래 프로모션 일정(11일)을 알려주자, 모델이 부여한 상승폭은 **32.55 / 21.74**. 일정을 지운 반사실 실행에서는 봉우리가 사라짐.

이것은 성능 증거가 아님. 공변량 입력 경로가 작동한 다는 확인일 뿐. 오차가 62% 줄어든 것도 우리가 그렇게 만들었기 때문임.

노란 띠 = 예정 프로모션. 주황(단변량)과 회색(naive)은 주간 봉우리만 따라가고, 파랑(다변량+공변량)만 프로모션 봉우리를 재현.

용어

합성 데이터

연구자가 수식으로 생성한 데이터. 정답 효과를 알 수 있어 도구 점검에 쓴다.

반사실(counterfactual)

'만약 프로모션이 없었다면'처럼 입력 하나만 바꿔 다시 예측해 그 입력의 기여를 재는 방법.

lift

프로모션 하루가 수요를 끌어올린 양.

S1. 실제 데이터 첫 시도: 하나는 성공, 하나는 실패

M5 Walmart 판매량 (16개 상품, 512일 → 28일)

방법	MAE
계절 naive	8.41
TimesFM 3 단변량	6.67
다변량	6.59
다변량+공변량	6.55

naive보다 **22.1%** 개선. 다변량·공변량의 추가 이득은 1.8%로 작지만 같은 방향.

Beijing 미세먼지 (4개 관측소, 14일 → 24시간)

방법	MAE
계절 naive	22.54
TimesFM 3 단변량	23.11
다변량	28.35
다변량+공변량	29.12

입력을 더 넣을수록 **나빠짐**. 다변량+공변량은 naive보다 29.2% 나쁨. 80% 예측 구간의 실제 적중률은 43~54%.

용어

M5

Walmart 판매 데이터 공개 대회 자료. 상품별 일별 판매량과 가격·행사 정보 포함.

SNAP


미국 식품 지원 프로그램. 지급일에 판매가 뛰어 공변량으로 사용.

PM2.5

지름 2.5μm 이하 초미세먼지 농도.

5. 결과 · S2

실패에서 배운 것: 공변량은 '개수'가 아니라 '미래를 설명하는가'



예측 구간의 실제 평균 농도는 **9.4**. 직전 24시간 평균은 약 31, 2주 평균은 86 안팎. **갑작스러운 청정 전환**이었음.

모델이 받은 보조 정보는 시간대·요일 뿐. 바람이 바뀔 것이라는 정보는 어디에도 없었으니, 어떤 모델도 맞힐 수 없는 **외부 충격**임.

실제 미래 기상값을 넣으면 맞겠지만 그건 **정보 누수**. 이 사례는 다변량 예측의 실패가 아니라 **레짐 전환·과신 스트레스 테스트**로 재분류함(사후 해석).

재설계 결정(S2): 관계가 실제 선행정보가 되는 데이터에서, 관련 입력 vs 무관 입력 **대조군**을 같은 시점에 비교한다.

용어

레짐 전환

데이터의 수준·패턴이 갑자기 다른 상태로 바뀌는 것.

정보 누수(leakage)

예측 시점에 알 수 없었던 미래 정보가 입력에 섞여 성능이 부풀려지는 오류.

과신

모델의 예측 구간이 실제보다 좁아 틀릴 때 크게 틀리는 상태.

주 실험 데이터: METR-LA 로스앤젤레스 고속도로 센서

- 2012년 3~6월, **207개 센서**가 5분마다 통행 속도 (mph) 기록
- 센서 간 **도로 방향과 거리**가 공개돼 있음
- 정체는 상류에서 하류로 **전파**되므로 옆 센서가 실제 선행정보가 될 수 있음
- DCRNN·STAEformer 등 교통 전용 모델의 표준 시험 데이터

왜 16개 센서만?

첫 질문은 "다변량 기능이 작동하는가"였음. 16개면 하루 안에 모든 조건을 같은 시점에서 비교할 수 있음. 207개 전체는 별도 2단계로 분리.

타깃 16개

도로망 거리로 묶은 센서 클러스터

인접 센서 4개

타깃별 도로망 최근접, 평균 1.66 km → **관련 입력**

원거리 센서 4개

타깃별 가장 먼 센서, 평균 26.8 km → **대조군**

같은 크기의 입력을 넣고 결과가 갈리면, 이득이 '관계'에서 왔다고 볼 수 있음.

용어

대조군(negative control)

효과가 없어야 정상인 조건. 관련 없는 먼 센서를 넣어 '입력이 늘어난 효과'와 '관계의 효과'를 구분.

도로 그래프

센서를 점, 도로 연결을 선으로 표현한 구조. 거리·방향 정보 포함.

mph

시간당 마일. 오차 1 mph $\approx$ 시속 1.6 km 차이.

S3. 탐색 결과 (10회 반복): 관련 입력과 무관 입력이 같았다

입력 방식	MAE (MPH)	단변량 대비	승률
계절 naive	10.18	+200%	0/10
TimesFM 3 단변량	3.39	—	—
16개 타깃 공동 예측	3.17	-6.36%	8/10
인접 센서 입력	3.22	-4.97%	9/10
원거리 센서 대조군	3.42	+0.84%	6/10

관련 입력은 좋아지고 무관 입력은 나빠졌음. RQ2에 긍정적인 첫 신호.

하지만 10회로는 부족했음. 10개 origin이 2주 안에 몰려 서로 독립이 아니고, 극단 하루가 평균을 흔들 수 있으며, 불확실성 구간을 계산하지 않았음. 센서 선택 구간이 평가 구간과 너무 가까웠음.

용어

승률 8/10

10번의 예측 시작점 중 8번에서 단변량보다 오차가 낮았다는 뜻.

negative transfer

관계 없는 입력이 오히려 예측을 방해하는 현상.

S4. 엄격화: 누수를 막고 40회로 늘리고 구간을 붙였다

① 센서 선택은 시계열 앞 절반만 보고

34,272개 시점 중 앞 **17,136**개로만 센서를 골랐고, 가장 이른 평가 입력은 **18,111**부터. **975** 시점 간격.

실행 전 점검에서 처음 계산식이 평가 구간과 겹칠 수 있음을 발견해 고침.

② 40개의 서로 겹치지 않는 시작점

2012-05-09 ~ 06-25, 하루 이상 간격. 7일 입력 → 1시간(12 시점) 예측.

③ 블록 부트스트랩 95% 구간

40개 차이값을 **7개씩 묶어** 복원 추출을 10,000번 반복해 평균 차이의 범위를 구함. 이웃한 날끼리의 상관을 흡수.

정식 검정이 아니라 '효과 방향이 안정적인가'의 지표로 읽음.

용어

부트스트랩

가진 표본을 무작위로 다시 뽑아 통계량의 흔들림을 재는 방법.

블록 부트스트랩

시간 순서가 있는 데이터에서 연속 구간(블록)째로 뽑아 이웃 상관을 보존하는 변형.

95% 구간이 0을 배제


다시 뽑아도 평균 차이가 거의 항상 같은 부호였다는 뜻. '효과가 우연은 아닐 가능성이 높다.'

S4. 40회 결과: 이득은 1~2%로 줄었지만 '반복'됐다

입력 방식	MAE	단변량 대비	승	95% 구간
단변량	2.611	—	—	—
공동 예측	2.576	-1.38%	30/40	[-0.059, -0.011]
인접 센서	2.566	-1.73%	29/40	[-0.077, -0.014]
원거리 대조군	2.607	-0.17%	23/40	[-0.031, 0.016]
인접+캘린더	2.566	-1.74%	32/40	[-0.069, -0.019]

10회의 5~6%가 40회에서 **1~2%**로. 이것은 실패가 아니라 **주장이 정확하게 보정된 것**임. 관련 입력의 구간은 0 아래, 대조군은 0을 포함.

인접 - 원거리 직접 비교 구간은 [-0.087, 0.003]. 상한이 0을 살짝 넘어 '관계 선택의 우월성'은 시사적, 미확정.



용어

MAE 2.611

40회 평균. 실제 속도와 예측이 평균 2.6 mph 차이.

[-0.059, -0.011]

다시 뽑아 구한 평균 차이의 95% 범위. 둘 다 음수 = 개선 방향이 안정적.

결가지: 도로 구조에 정보가 있는가? (진단용 기준선)

선형 기준선	MAE	비교		95% 구간
자기 이력만 쓰는 ridge 회귀	3.156	-		-
+ 실제 도로 그래프 확산 특성	3.270	자기 이력 대비	+3.6%	$[-0.050, 0.277]$ (0 포함)
+ 섞어 놓은 가짜 그래프	3.418	실제 그래프 대비	+4.3%	$[-0.245, -0.046]$ (0 배제)

실제 그래프 > 가짜 그래프: 도로 구조에는 예측 정보가 있음. **그래프 < 자기 이력:** 단순 선형 확산은 그 정보를 살리지 못했음.

이 ridge는 **진단용**임. DCRNN 논문의 발상(도로 방향·거리, 양방향 확산)만 빌린 선형 모델이라, 진짜 DCRNN과의 비교가 아님. TimesFM이 이것보다 21% 낮다는 사실은 '전용 모델보다 낮다'는 뜻이 아님.

용어

ridge 회귀

과거 값들의 가중합으로 미래를 맞히는 선형 모델. 가중치가 너무 커지지 않게 벌점을 둔 것.

확산(diffusion)

한 센서의 정체가 도로를 따라 이웃으로 번지는 것을 수식으로 흉내 낸 특성.

셔플 그래프

센서 라벨을 무작위로 섞어 연결 정보를 망가뜨린 가짜 그래프. 그래프 효과의 대조군.

S5. 모델 비교 설계: 두 트랙을 섞지 않는다

트랙 A Zero-shot 파운데이션 모델

- TimesFM 3 (Google) vs Chronos-2 (Amazon)
- 같은 16센서, 같은 40개 시작점, 같은 7일 입력 (2,016 시점)
- 이 데이터로 학습 **전혀 없음**

트랙 B 교통 전용 학습 모델

- DCRNN (도로 그래프 신경망) vs STAEformer (트랜스포머)
- 시계열 앞 절반(13,685개 창)으로 **직접 학습**, 검증 오차로 조기 종료
- 표준 설정: 1시간 입력 → 1시간 출력. 각 1회 (seed 1개) 학습

두 트랙은 학습 예산과 입력 정보량이 다르므로 **한 줄의 순위표로 읽지 않음**. 전용 모델이 낮으면 '도메인 학습의 상한', zero-shot이 근접하면 '학습 없이 얻은 효율'로 해석함. 평가 40개 시작점은 어떤 모델 선택에도 쓰지 않았음.

용어

supervised(지도) 학습

정답이 있는 과거 데이터로 모델의 파라미터를 직접 맞추는 것.

seed

학습의 무작위 초기값. 하나만 돌리면 운에 따른 편차를 썰 수 없다.


조기 종료

검증 오차가 더 안 줄면 학습을 멈추는 규칙. 과적합 방지.

S5. 결과: Chronos-2보다 낮고, DCRNN과는 판정 보류

모델	MAE	VS TIMESFM 3 다변량
TimesFM 3 다변량 (zero-shot)	2.576	—
TimesFM 3 단변량	2.611	+1.4%
Chronos-2 다변량 (zero-shot)	2.718	+5.5%, 구간 [-0.193, -0.095] 0 배제
DCRNN (학습)	2.741	+6.4%, 구간 [-0.006, 0.371] 0 포함
STAEformer (학습)	2.802	+8.8%, 구간 [0.038, 0.446]

- TimesFM 3 다변량은 Chronos-2 다변량보다 5.24% 낮고 28/40 승. Chronos-2 자체의 다변량 이득은 구간이 0을 포함해 반복되지 않음.
- DCRNN과의 구간이 0에 걸쳐 **우열 미확정**. 평균만 보면 TimesFM이 낮지만 그렇게 말하지 않음.



용어

+5.5% vs -5.24%

같은 차이를 어느 쪽 기준으로 나누느냐의 차이. 논문은 TimesFM 기준 -5.24%로 표기.

판정 보류

구간이 0을 포함하면 다시 실험했을 때 부호가 바뀔 수 있어 승패를 선언하지 않음.

보조 실험: M5 판매량에서는 '관계 특이적' 이득이 없었다

입력 방식 (같은 8개 상품 × 캘리포니아 3개 매장 = 24 타깃, 5회 반복)	MAE	단변량 대비
TimesFM 3 단변량	9.85	—
24개 타깃 공동 예측	9.39	-4.73%
같은 상품·다른 매장을 보조 입력으로 (관련 입력)	9.83	-0.21%
다른 상품·다른 매장을 보조 입력으로 (대조군)	9.42	-4.34%

공동 예측의 이득은 있었지만, '같은 상품'이라는 관계는 대조군보다 낮지 않았음. 즉 판매 데이터에서는 입력을 묶는 일반적 효과이지, 매장 간 동일 상품 정보가 특별히 유효하다는 증거가 아님.

5회 반복으로는 작은 차이를 확정할 수 없음. 교통 데이터와 대비되는 결과로, "관계가 실제 선행정보인가"가 관건임을 보여줌.

용어

SKU

재고 관리 단위. 여기서는 '상품 하나'.

관계 특이적 이득

아무 시계열이 아니라 '바로 그 관계'가 있는 시계열이어야 생기는 이득.

외부 검증: 구글 공개 수치를 재현할 수 있었나

FEV-BENCH 과제	로컬 SQL	구글 공개 SQL	차이	데이터 지문 일치
ETT_1W (변압기 유온·부하 7변수)	2.434	2.401	+1.40%	아니오
UCI Air Quality 1D (대기질 4타겟)	1.030	1.091	-5.54%	아니오
GVAR (6타겟+과거 공변량)	0.568	0.567	+0.19%	아니오

세 과제의 절대 차이 평균 **2.38%**. 같은 환경에서 다시 돌리면 소수점까지 동일(결정적).

현재 내려받은 데이터의 지문이 구글 기록과 모두 달라, 이것은 **근접 재현**이지 비트 단위 재현이 아님. 100개 과제 전체를 재현했다고도 말하지 않음.

용어

FEV-Bench

AutoGluon이 만든 공개 예측 벤치마크. 구글이 TimesFM 3 성적표를 여기에 공개.

SQL

Scaled Quantile Loss. 확률 예측의 정확도 지표. 낮을수록 좋음.

데이터 지문(fingerprint)

데이터 파일 내용의 요약값. 다르면 같은 이름이라도 내용이 다르다는 뜻.

언제 돕고, 언제 해치는가

도움이 된 조건

- 입력에 실제 선행정보가 있을 때 — 옆 도로 센서(정체 전파)
- 미래에 이미 아는 변화를 공변량으로 줄 때 — 행사·가격·SNAP
- 타깃끼리 공통 변동을 공유할 때 — 공동 예측(판매·교통 모두)

중립이거나 해친 조건

- 미래 변화의 원인이 입력에 없을 때 — Beijing 청정 전환
- 관계 약한 시계열을 섞을 때 — 먼 센서: 10회에서는 악화, 40회에서는 중립
- 반복 주기만 설명하는 공변량을 짧은 예측에 더할 때 — 1시간 예측에 요일 정보

40회에서 다변량 이득은 MAE 약 0.04 mph, 상대 1~2%. 실무적으로 작지만 **추가 학습 없이 입력 구성만으로 반복 획득되는 이득**임. 같은 조건에서 Chronos-2는 이 이득을 보이지 않았음. 다만 그 차이가 모델 구조 때문인지 사전학습 데이터 때문인지는 이 실험으로 분리할 수 없음.

용어

선행정보

미래 값이 움직이기 전에 먼저 움직이는 신호. 상류 정체는 하류 정체의 선행정보.

입력 선택

어떤 시계열을 함께 넣을지 고르는 일. 모델이 알아서 걸러 주지 않는다는 것이 이번 교훈.

응용 함의: 보험 업무에서는 어디에 쓸 수 있나 (가설)

실험 조건에 맞는 시계열

- 채널별 콜센터 인입·청구 접수 건수 — 관련 채널끼리 공동 예측 + 요일·공휴일·납입일·캠페인 일정을 미래 공변량으로
- 보험료 수납·자동이체 실패 건수 — 급여일·명절이 미래 변화를 설명
- 정비·의료기관별 청구 물량, 수리비 지수 — 공통 변동을 공유하는 묶음
- 월별 지급액 단기 추세 — 준비금 추정의 보조 기준선(대체 아님)
- 이력 짧은 신상품·신규 지역 — 학습 없이 즉시 기준선

부적합하거나 주의

- 태풍·폭우·한파 청구 급증 — Beijing과 같은 외생 전환. 예보만 공변량으로, 실제 미래 기상값은 누수
- 제도·요율 변경 직후 — 변경 시점을 알려주지 않으면 근거 없음
- 손해율·발생손해액 — 희소 사건·두꺼운 꼬리, 실험 범위 밖
- 계약별 해지·사고 확률 — 분류 문제, 대상 아님

용어

지급준비금

이미 발생했지만 아직 지급하지 않은 보험금을 위해 쌓아 두는 금액. 회계 기준으로 추정.

손해율

받은 보험료 대비 지급한 보험금의 비율.

분류 문제

'해지한다/안 한다'처럼 범주를 맞추는 과제. 시계열의 다음 값을 맞추는 예측과 다름.

검증 전에는 결론이 아니라 검토 항목임. 함께 넣을 시계열은 사람이 고르고, 가치는 정확도보다 "학습 없이 즉시 기준선"의 속도에 있으며, 사내 검증은 이 연구의 절차(naive 대비, 40회 반복, 관련 vs 무관 대조군)를 그대로 씀. 현재 라이선스는 비상업·비프로덕션 전용임.

7. 한계

한계: 이 결과가 말하지 않는 것

16센서 부분 그래프

전용 모델은 207개 중 16개만으로 학습. 바깥 이웃이 잘려 **그래프 모델에 불리**할 수 있음. 공개된 DCRNN·STAEformer 표준 점수와 직접 비교 금지.

입력 길이 불일치

zero-shot은 7일(2,016 시점), 전용 모델은 표준 1시간(12 시점). 정보량이 다름.

학습 1회

전용 모델을 seed 하나로만 학습. 초기값에 따른 편차 미측정. DCRNN과의 구간이 0에 걸친 상태에서 어느 쪽으로도 움직일 수 있음.

사전학습 중복 미확인

TimesFM 3·Chronos-2가 사전학습 때 METR-LA를 봤는지 독립 확인 불가. 여기서 zero-shot은 '로컬 학습 없음'의 뜻.

작은 시간 창

40개 시작점은 7주 안에 있고, 결측 없는 구간만 선택. 전체 기간의 무작위 표본이 아님. 다중비교 보정 없음.

라이선스

TimesFM 3 가중치는 **비상업·비프로덕션** 전용. 이 결과로 운영 배포를 정당화할 수 없음.

용어

induced subgraph

전체 그래프에서 일부 점만 남기고 그 사이 연결만 유지한 부분 그래프.

다중비교

여러 비교를 동시에 하면 우연히 하나쯤은 유의해 보일 수 있는 문제.

8. 결론

결론과 다음 단계의 경계

TimesFM 3의 다변량 모드는 유용하며, 시계열 사이에 실제 신호가 있을 때 작지만 반복 가능한 이득을 낸다. 같은 16센서 METR-LA zero-shot 조건에서 Chronos-2보다 우수했다. 이 결과는 TimesFM 3가 DCRNN·STAEformer보다 일반적으로 우월하다는 것도, 다변량 입력이 항상 도움이 된다는 것도 확립하지 않는다.

연구 질문별 답

- **RQ1** 예, 단 작다(-1.4~-1.7%, 구간 0 배제)
- **RQ2** 부분적으로 예. 교통에서는 관계가 같았고 판매에서는 아니었다
- **RQ3** Chronos-2보다 낮음. DCRNN 미확정. STAEformer보다 이 패널에서 낮음

2단계를 여는 조건 (지금은 열지 않음)

- 207개 센서 전체와 표준 분할, 15·30·60분 지표
- 전용 모델 seed 3개 이상
- zero-shot 모델의 입력 길이 12 vs 2,016 비교
- 학습 비용과 추론 비용의 분리 보고

용어

표준 분할

해당 분야 논문들이 공통으로 쓰는 학습/검증/평가 구간 나누기. 결과를 서로 비교하려면 필요.

재현 정보

환경

- Apple M4 · macOS 26.5.2 · Python 3.13.12
· torch 2.13.0 · MPS
- TimesFM 소스 커밋 7360853 · 가중치
google/timesfm-3.0-pytorch
- Chronos-2: amazon/chronos-2, chronos-
forecasting 2.3.1
- DCRNN·STAEformer: Torch-MTS 커밋 2db4de3
- FEV 0.9.0 · uv.lock으로 의존성 고정

검증

- 원본 데이터 5개 파일 체크섬 일치
- 결과 JSON 11개에서 모든 표를 재계산
- 학습 모델 체크포인트를 새 인스턴스에 로드해 40회 재평가
- Chronos-2 재실행이 저장 결과와 일치
- 테스트 26개 통과, 정적 검사 통과

데이터 출처

M5: Kaggle (Zenodo 보존본) · Beijing: UCI, CC BY 4.0 ·
METR-LA: DCRNN 저장소 공개 파일 · FEV: AutoGluon

용어

체크섬

파일 내용의 지문. 내려받은 파일이 원본과
같은지 확인.

체크포인트

학습 도중 저장한 모델의 파라미터 파일.

용어 한 장 정리

시계열	시간 순서의 숫자 나열
공변량	예측을 돕는 보조 시계열 (과거 전용 / 미래까지 아는)
파운데이션 모델	미리 크게 학습해 둔 범용 모델
계절 naive	"지난 주기와 같다"고 찍는 기준선
rolling origin	시작점을 옮겨가며 반복 평가
정보 누수	미래 정보가 입력에 섞이는 오류
supervised	해당 데이터로 직접 학습한 모델

단변량 / 다변량	한 줄씩 따로 / 여러 줄을 함께
zero-shot	추가 학습 없이 바로 예측
MAE	예측 오차 절댓값의 평균
holdout / origin	숨겨둔 평가 구간 / 예측 시작 시점
대조군	효과가 없어야 정상인 비교 조건
블록 부트스트랩 구간	연속 구간째 재추출로 구한 평균 차이의 범위
레짐 전환	데이터 패턴이 갑자기 바뀌는 것

감사합니다

질문 환영

논문 v10과 결과 JSON, 체크포인트, 재현 명령은 프로젝트 저장소 docs/와 artifacts/에 있음.